

机器学习的数学笔记

X

目录

| | |
|----------------------------|-----------|
| 符号表 | iii |
| 1 方法概论 | 1 |
| 1.1 基本概念 | 1 |
| 1.2 泛化误差 | 2 |
| 2 逻辑回归 | 3 |
| 2.1 二项逻辑回归模型 | 3 |
| 2.2 Softmax回归模型 | 5 |
| 3 主成分分析 | 8 |
| 3.1 主成分分析的算法 | 8 |
| 3.2 主成分分析的数学原理 | 9 |
| 4 附录：数学基本方法 | 12 |
| 4.1 梯度 | 12 |
| 5 附录：概率论中的重要结论 | 14 |
| 5.1 Hoeffding不等式 | 14 |
| 6 附录：信息熵 | 16 |
| 6.1 相关概念 | 16 |
| 6.2 熵的性质 | 18 |
| 7 附录：贝叶斯决策论 | 24 |
| 7.1 先验概率与后验概率 | 24 |
| 7.2 共轭分布 | 25 |
| 参考文献 | 27 |

符号表

下面列出了本文所用的数学符号对照表，具体可参照Goodfellow *et al.* (2016)的2-4章节。

数字和数组

| | |
|---------------------------|---|
| a | 标量(整数或实数) |
| \mathbf{a} | 向量(矢量) |
| \mathbf{A} | 矩阵 |
| \mathbf{A} | 张量 |
| \mathbf{I}_n | n 行 n 列的单位矩阵 |
| \mathbf{I} | 单位矩阵，维度参见上下文 |
| $\mathbf{e}^{(i)}$ | 标准基向量 $[0, \dots, 0, 1, 0, \dots, 0]$ ，其中第 i 位为 1 |
| $\text{diag}(\mathbf{a})$ | 正方形对角矩阵，其中对角线元素为 \mathbf{a} |
| a | 随机变量，标量 |
| \mathbf{a} | 随机变量，向量 |
| \mathbf{A} | 随机变量，矩阵 |

集合和图

| | |
|-----------------------------------|---|
| \mathbb{A} | 集合 |
| \mathbb{R} | 实数集合 |
| $\{0, 1\}$ | 包含 0 和 1 的集合 |
| $\{0, 1, \dots, n\}$ | 从 0 到 n 的所有整数的集合 |
| $[a, b]$ | a 到 b 的实数闭区间 |
| $(a, b]$ | a 到 b 的实数半开区间 |
| $\mathbb{A} \setminus \mathbb{B}$ | 差集, 即集合包含了在 \mathbb{A} 中但不在 \mathbb{B} 中的元素 |
| \mathcal{G} | 图 |
| $Pa_{\mathcal{G}}(\mathbf{x}_i)$ | 图 \mathcal{G} 中节点 \mathbf{x}_i 的双亲 |

角标

| | |
|----------------------|--|
| a_i | 向量 \mathbf{a} 的第 i 个元素, 其中角标从 1 开始 |
| a_{-i} | 向量 \mathbf{a} 除第 i 个元素以外的所有元素 |
| $A_{i,j}$ | 矩阵 \mathbf{A} 的第 i 行第 j 列的元素 |
| $\mathbf{A}_{i,:}$ | 矩阵 \mathbf{A} 的第 i 行 |
| $\mathbf{A}_{:,i}$ | 矩阵 \mathbf{A} 的第 i 列 |
| $A_{i,j,k}$ | 3-D 张量 \mathbf{A} 的元素 (i, j, k) |
| $\mathbf{A}_{:,:,i}$ | 3-D 张量的 2-D 切片 |
| \mathbf{a}_i | 随机向量 \mathbf{a} 的第 i 个元素 |

线性代数

| | |
|-------------------------------|---|
| \mathbf{A}^{\top} | 矩阵 \mathbf{A} 的转置 |
| \mathbf{A}^{+} | 矩阵 \mathbf{A} 的摩尔彭罗斯伪逆 (广义逆) |
| $\mathbf{A} \odot \mathbf{B}$ | 矩阵 \mathbf{A} 和 \mathbf{B} 的元素积 (Hadamard 乘积) |
| $\det(\mathbf{A})$ | 矩阵 \mathbf{A} 的行列式 |

微积分

| | |
|--|--|
| $\frac{dy}{dx}$ | y 关于 x 的导数 |
| $\frac{\partial y}{\partial x}$ | y 关于 x 的偏导数 |
| $\nabla_{\mathbf{x}} y$ | y 关于向量 \mathbf{x} 的梯度 |
| $\nabla_{\mathbf{X}} y$ | y 关于矩阵 \mathbf{X} 的导数 |
| $\nabla_{\mathbf{X}} y$ | y 关于张量 \mathbf{X} 的导数 |
| $\frac{\partial f}{\partial \mathbf{x}}$ | $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 的雅克比矩阵 $\mathbf{J} \in \mathbb{R}^{m \times n}$ |
| $\nabla_{\mathbf{x}}^2 f(\mathbf{x})$ or $\mathbf{H}(f)(\mathbf{x})$ | f 在输入向量 \mathbf{x} 的海森矩阵 |
| $\int f(\mathbf{x}) d\mathbf{x}$ | 在整个定义域上 f 关于 \mathbf{x} 的定积分 |
| $\int_{\mathbb{S}} f(\mathbf{x}) d\mathbf{x}$ | 在集合 \mathbb{S} 上 f 关于 \mathbf{x} 的定积分 |

概率论与信息论

| | |
|--|---|
| $\mathbf{a} \perp \mathbf{b}$ | 随机变量 \mathbf{a} 与 \mathbf{b} 相互独立 |
| $\mathbf{a} \perp \mathbf{b} \mid \mathbf{c}$ | 随机变量 \mathbf{a} 与 \mathbf{b} 对于给定的 \mathbf{c} 条件独立 |
| $P(\mathbf{a})$ | 离散变量的概率分布 |
| $p(\mathbf{a})$ | 连续变量的概率分布或类型不确定的变量的概率分布 |
| $\mathbf{a} \sim P$ | 随机变量 \mathbf{a} 服从 P 分布 |
| $\mathbb{E}_{\mathbf{x} \sim P}[f(\mathbf{x})]$ or $\mathbb{E}f(\mathbf{x})$ | $f(\mathbf{x})$ 在概率分布 $P(\mathbf{x})$ 的期望 |
| $\text{Var}(f(\mathbf{x}))$ | $f(\mathbf{x})$ 在概率分布 $P(\mathbf{x})$ 下的方差 |
| $\text{Cov}(f(\mathbf{x}), g(\mathbf{x}))$ | $f(\mathbf{x})$ 和 $g(\mathbf{x})$ 在概率分布 $P(\mathbf{x})$ 下的协方差 |
| $H(\mathbf{x})$ | 随机变量 \mathbf{x} 的信息熵 |
| $D_{\text{KL}}(P \parallel Q)$ | 随机变量 P 与 Q 的相对熵(KL散度) |
| $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ | 均值为 $\boldsymbol{\mu}$ 方差为 $\boldsymbol{\Sigma}$ 的 \mathbf{x} 的高斯分布 |

函数

| | |
|--|--|
| $f: \mathbb{A} \rightarrow \mathbb{B}$ | 定义域为 \mathbb{A} 值域为 \mathbb{B} 的函数 f |
| $f \circ g$ | 函数 f 和 g 的复合函数 |
| $f(\mathbf{x}; \boldsymbol{\theta})$ | 参数为 $\boldsymbol{\theta}$ 的关于 \mathbf{x} 的函数. (有时我们写作 $f(\mathbf{x})$ 而忽略参数 $\boldsymbol{\theta}$ 来简化符号) |
| $\log x$ | x 的自然对数 |
| $\sigma(x)$ | Logistic sigmoid 函数, $\frac{1}{1 + \exp(-x)}$ |
| $\zeta(x)$ | Softplus 函数, $\log(1 + \exp(x))$ |
| $\ \mathbf{x}\ _p$ | \mathbf{x} 的 L^p 范数 |
| $\ \mathbf{x}\ $ | \mathbf{x} 的 L^2 范数 |
| x^+ | x 的正值部分, 即 $\max(0, x)$ |
| $\mathbf{1}_{\text{condition}}$ | 如果条件为真则值为1, 条件为假则值为0 |

有时我们把参数为标量的函数 f 应用到矢量、矩阵或张量中: $f(\mathbf{x})$, $f(\mathbf{X})$, 或 $f(\mathbf{X})$ 。这代表着将 f 应用到数组元素层面, 例如, 如果 $\mathbf{C} = \sigma(\mathbf{X})$, 那么任意 i, j 和 k , 都有 $C_{i,j,k} = \sigma(X_{i,j,k})$

数据集和分布

| | |
|---------------------------------|--|
| p_{data} | 数据生成的概率分布 |
| \hat{p}_{data} | 训练集生成(定义)的经验分布 |
| \mathbb{X} | 训练集 |
| $\mathbf{x}^{(i)}$ | 数据集集中的第 i 个(输入)实例 |
| $y^{(i)}$ or $\mathbf{y}^{(i)}$ | 有监督学习下 $\mathbf{x}^{(i)}$ 对应的标记 |
| \mathbf{X} | $m \times n$ 的矩阵, 其中输入实例 $\mathbf{x}^{(i)}$ 在 $\mathbf{X}_{i,:}$ 行 |

Chapter 1

方法概论

本章讨论**监督学习**的基本方法与概念，内容参考了李航 (2012)和Rigollet (2015)。

1.1 基本概念

1.1.1 模型

用 X 和 Y 表示输入空间 \mathcal{X} 和输出空间 \mathcal{Y} 上的变量，用 θ 表示参数向量，模型的假设空间一般有两种情况

- 决策函数的集合 $\mathcal{F} = \{f|Y = f_{\theta}(X)\}$ ，此类模型称为**非概率模型**
- 条件概率的集合 $\mathcal{F} = \{P|P_{\theta}(Y|X)\}$ ，此类模型称为**概率模型**

1.1.2 策略

1.1.2.1 损失函数

度量输出的预测值 $f(X)$ 与真实值 Y 差异程度的函数称为**损失函数**，记做 $L(Y, f(X))$ ，通常的损失函数有0-1损失，平方损失等。

常用的损失函数有0-1损失，平方损失，对数损失等。

用损失函数的期望来度量模型 f 在联合分布 $P(X, Y)$ 下的平均损失，也成为称为**风险**

函数或期望风险。

$$R_{\text{exp}}(f) = \mathbb{E}[L(Y, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(Y, f(X)) dP(X, Y)$$

学习的目标是选择期望最小的模型。然而实践中联合概率分布 $P(X, Y)$ 是未知的，只能用经验风险来估计。

给定一个训练集 $\mathbb{X} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$

$$R_{\text{emp}}(f) = \frac{1}{N} \sum_{i=1}^N L(y_i, f(\mathbf{x}_i))$$

根据监督学习的基本假设，训练数据和测试数据都是依 $P(X, Y)$ 独立同分布产生的，所以 $R_{\text{emp}}(f)$ 是 $R_{\text{exp}}(f)$ 的无偏估计。根据大数定律， $R_{\text{emp}}(f)$ 收敛于 $R_{\text{exp}}(f)$ 。

1.2 泛化误差

假设学习到的模型为 \hat{f} ，那么该模型的泛化误差定义为该模型的期望风险：

$$R_{\text{exp}}(\hat{f}) = \mathbb{E}[L(Y, \hat{f}(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(Y, \hat{f}(X)) dP(X, Y) \quad (1.1)$$

1.2.1 二类分类问题

下文以二类分类问题为例，讨论模型的泛化误差。

假设模型的输入空间 $\mathcal{X} = \mathbb{R}^n$ ，输出空间 $\mathcal{Y} = \{-1, 1\}$ 。模型的决策函数空间是有限集合 $\mathcal{F} = \{f_1, f_2, \dots, f_d\}$ ，损失函数是0-1损失。

Theorem 1.2.1. 对于二类分类问题，当假设空间是有限个函数的集合 $\mathcal{F} = \{f_1, f_2, \dots, f_d\}$ 时，对于任意 $f \in \mathcal{F}$ ，至少以概率 $1 - \delta$ ，以下关于期望风险 $R(f)$ 和经验风险 $\hat{R}(f)$ 关系的不等式成立

$$R(f) \leq \hat{R}(f) + \sqrt{\frac{\log(d/\delta)}{2N}} \quad (1.2)$$

Chapter 2

逻辑回归

2.1 二项逻辑回归模型

二项逻辑回归模型是如下的条件概率分布

$$P(Y = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^T \mathbf{x} + b)}{1 + \exp(\boldsymbol{\theta}^T \mathbf{x} + b)}$$
$$P(Y = 0|\mathbf{x}) = \frac{1}{1 + \exp(\boldsymbol{\theta}^T \mathbf{x} + b)}$$

其中 $\mathbf{x} \in \mathbb{R}^n$ 是输入变量， $Y \in \{0, 1\}$ 是输出变量， $\boldsymbol{\theta} \in \mathbb{R}^n$ 和 $b \in \mathbb{R}$ 是参数。 \mathbf{x} 和 $\boldsymbol{\theta}$ 为 n 维列向量。

若令 $\boldsymbol{\theta} = (\theta^{(1)}, \dots, \theta^{(n)}, b)^T$ ， $\mathbf{x} = (x^{(1)}, \dots, x^{(n)}, 1)^T$ ，那么条件概率可以表示为

$$P(Y = 1|\mathbf{x}) = \frac{\exp(\boldsymbol{\theta}^T \mathbf{x})}{1 + \exp(\boldsymbol{\theta}^T \mathbf{x})}$$
$$P(Y = 0|\mathbf{x}) = \frac{1}{1 + \exp(\boldsymbol{\theta}^T \mathbf{x})} \quad (2.1)$$

2.1.1 模型的参数估计

对于给定的训练集 $\mathbb{X} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$ ，可应用极大似然估计法估计模型参数。

为表示方便，令 $P(Y = 1|\mathbf{x}) = \pi(\mathbf{x})$ ， $P(Y = 0|\mathbf{x}) = 1 - \pi(\mathbf{x})$ ，似然函数为

$$L(\boldsymbol{\theta}) = \prod_{i=1}^N (\pi(\mathbf{x}_i))^{y_i} (1 - \pi(\mathbf{x}_i))^{1-y_i}$$

那么对数似然函数为

$$\begin{aligned}
 \log L(\boldsymbol{\theta}) &= \sum_{i=1}^N (y_i \log \pi(\mathbf{x}_i) + (1 - y_i) \log(1 - \pi(\mathbf{x}_i))) \\
 &= \sum_{i=1}^N \left(y_i \log \frac{\pi(\mathbf{x}_i)}{1 - \pi(\mathbf{x}_i)} + \log(1 - \pi(\mathbf{x}_i)) \right) \\
 &= \sum_{i=1}^N (y_i (\boldsymbol{\theta}^T \mathbf{x}_i) - \log(1 + \exp(\boldsymbol{\theta}^T \mathbf{x}_i)))
 \end{aligned} \tag{2.2}$$

2.1.1.1 参数估计：梯度下降法

根据公式 (2.2)，对数似然函数对 $\boldsymbol{\theta}$ 的偏导为

$$\begin{aligned}
 \nabla_{\boldsymbol{\theta}} \log L(\boldsymbol{\theta}) &= \sum_{i=1}^N \left(y_i \mathbf{x}_i - \frac{\exp(\boldsymbol{\theta}^T \mathbf{x}_i) \mathbf{x}_i}{1 + \exp(\boldsymbol{\theta}^T \mathbf{x}_i)} \right) \\
 &= \sum_{i=1}^N (y_i - \pi(\mathbf{x}_i)) \mathbf{x}_i
 \end{aligned}$$

由此处求对数似然函数的最大值，故需要沿着梯度上升的方向进行迭代，迭代公式为

$$\begin{aligned}
 \boldsymbol{\theta} &:= \boldsymbol{\theta} + \alpha \frac{\partial}{\partial \boldsymbol{\theta}} \log L(\boldsymbol{\theta}) \\
 &= \boldsymbol{\theta} + \alpha \sum_{i=1}^N (y_i - \pi(\mathbf{x}_i)) \mathbf{x}_i
 \end{aligned} \tag{2.3}$$

其中 α 称为学习率，是一个正常数。

公式 (2.3)可以用矩阵表示

$$\boldsymbol{\theta} := \boldsymbol{\theta} + \alpha X^T \boldsymbol{\Lambda} \tag{2.4}$$

其中 $\boldsymbol{\Lambda} = \begin{pmatrix} y_1 - \pi(\mathbf{x}_1) \\ y_2 - \pi(\mathbf{x}_2) \\ \dots \\ y_N - \pi(\mathbf{x}_N) \end{pmatrix}_{N \times 1}$ ， X 是由训练数据构成的 $N \times (n + 1)$ 矩阵(每一行对应一个样本，每一列对应样本的一个维度，其中还包括一维常数项)。

2.1.1.2 参数估计：随机梯度下降法

梯度下降算法在每次更新回归系数时需要遍历整个数据集，当数据集数量庞大或者

特征过多时，该方法的计算复杂度太高。改进方法是每次迭代仅用一个样本来更新回归系数，称为随机梯度下降法。

具体而言，对于训练集中的每一个样本 (x_i, y_i) ，计算该样本梯度，并依据迭代公式：

$$\boldsymbol{\theta} := \boldsymbol{\theta} + \alpha (y_i - \pi(\mathbf{x}_i)) \mathbf{x}_i \quad (2.5)$$

与公式 (2.3) 相比，随机梯度下降的迭代公式 (2.5) 中

- 误差变量是数值，而不是向量
- 不再有矩阵变换的过程

所以随机梯度下降算法的计算效率较高，缺点是存在解的不稳定性(如解存在周期性波动)的问题。为了解决这一问题，并进一步加快收敛速度，可以通过随机选取样本来更新回归系数。

2.2 Softmax回归模型

Softmax模型是二项回归模型在多分类问题上的推广，在多分类问题中，类标签 Y 可以取两个以上的值。

假设 Y 的取值集合是 $\{1, 2, \dots, K\}$ ，Softmax模型是如下的条件概率分布

$$P(Y = k | \mathbf{x}) = \frac{\exp(\boldsymbol{\theta}_k^T \mathbf{x})}{\sum_{j=1}^K \exp(\boldsymbol{\theta}_j^T \mathbf{x})} \quad (2.6)$$

其中 $\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K \in \mathbb{R}^{n+1}$ 是模型的参数。

为方便起见，下文用矩阵 $\boldsymbol{\Theta}_{K \times (n+1)}$ 表示全部的模型参数

$$\boldsymbol{\Theta} = \begin{bmatrix} \boldsymbol{\theta}_1^T \\ \vdots \\ \boldsymbol{\theta}_K^T \end{bmatrix}$$

2.2.1 模型的参数估计

令 $P(Y = k | \mathbf{x}) = \pi_k(\mathbf{x})$ ，与二项逻辑回归类似，Softmax的似然函数可以表示为

$$L(\boldsymbol{\Theta}) = \prod_{i=1}^N \prod_{k=1}^K (\pi_k(\mathbf{x}_i))^{1_{y_i=k}}$$

对数似然函数为

$$\log L(\Theta) = \sum_{i=1}^N \sum_{k=1}^K \mathbf{1}_{y_i=k} \log \pi_k(\mathbf{x}_i) \quad (2.7)$$

2.2.1.1 参数估计：梯度下降法

首先求

$$\frac{\partial \pi_k(\mathbf{x}_i)}{\partial \theta_k} = \frac{\mathbf{x}_i \exp(\theta_k^T \mathbf{x}_i) \left(\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}) - \exp(\theta_k^T \mathbf{x}_i) \right)}{\left(\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}) \right)^2} \quad (2.8)$$

故根据公式 (2.7)，得到Softmax模型的对数似然函数的梯度

$$\begin{aligned} \nabla_{\theta_k} \log L(\Theta) &= \sum_{i=1}^N \mathbf{1}_{y_i=k} \frac{1}{\pi_k(\mathbf{x}_i)} \frac{\partial \pi_k(\mathbf{x}_i)}{\partial \theta_k} \\ &= \sum_{i=1}^N \mathbf{1}_{y_i=k} \frac{1}{\pi_k(\mathbf{x}_i)} \frac{\mathbf{x}_i \exp(\theta_k^T \mathbf{x}_i) \left(\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}_i) - \exp(\theta_k^T \mathbf{x}_i) \right)}{\left(\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}_i) \right)^2} \\ &= \sum_{i=1}^N \mathbf{1}_{y_i=k} \frac{\mathbf{x}_i \left(\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}_i) - \exp(\theta_k^T \mathbf{x}_i) \right)}{\sum_{j=1}^K \exp(\theta_j^T \mathbf{x}_i)} \\ &= \sum_{i=1}^N \mathbf{1}_{y_i=k} \mathbf{x}_i (1 - \pi_k(\mathbf{x}_i)) \end{aligned} \quad (2.9)$$

对于任意第 k 个分类的参数 θ_k ，可沿着梯度上升的方向进行迭代

$$\theta_k := \theta_k + \alpha \sum_{i=1}^N \mathbf{1}_{y_i=k} \mathbf{x}_i (1 - \pi_k(\mathbf{x}_i)) \quad (2.10)$$

公式 (2.10)的迭代关系用矩阵可以表示为

$$\theta_k := \theta_k + \alpha X^T \Lambda \quad (2.11)$$

其中 $\mathbf{\Lambda} = \begin{pmatrix} \mathbf{1}_{y_1=k}(1 - \pi_k(\mathbf{x}_1)) \\ \mathbf{1}_{y_2=k}(1 - \pi_k(\mathbf{x}_2)) \\ \dots \\ \mathbf{1}_{y_N=k}(1 - \pi_k(\mathbf{x}_N)) \end{pmatrix}_{N \times 1}$, X 是由训练数据构成的 $N \times (n + 1)$ 矩阵(每一行对应一个样本, 每一列对应样本的一个维度, 其中还包括一维常数项)。

Chapter 3

主成分分析

主成分分析（Principal Component Analysis, PCA）是一种常见的**数据降维**方法，其目的是在信息量损失较小的前提下，将高维的数据转换到低维，从而减小计算量。实质就是找到一些投影方向，使得数据在这些投影方向上包含的信息量最大，而且这些投影方向是相互正交的。选择其中一部分包含最多信息量的投影方向作为新的数据空间，同时忽略包含较小信息量的投影方向，从而达到降维的目的。

样本的**信息量**可以理解为是样本在特征方向上投影的方差。方差越大，则样本在该特征上的差异就越大，因此该特征就越重要。参见《机器学习实战》上的图，在分类问题里，样本的方差越大，越容易将不同类别的样本区分开。

PCA的数学原理，就是对原始的空间中顺序地找一组相互正交的坐标轴，第一个轴是使得方差最大的，第二个轴是在与第一个轴正交的平面中使得方差最大的，第三个轴是在与第1、2个轴正交的平面中方差最大的，这样假设在N维空间中，可以找到N个这样的坐标轴，取前r个去近似这个空间，这样就从一个N维的空间压缩到r维的空间了，但是最终选择的r个坐标轴能够使得数据的损失最小。

3.1 主成分分析的算法

假设

- 存在n个原始数据，每个数据有p个特征，用矩阵表示为 $\mathbf{Z}_{n \times p} = (\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_n)^T$ ，其中 \mathbf{z}_i 为p维列向量。

1. 去除平均值，即中心化，将数据**中心化**变换为 $\mathbf{X}_{n \times p} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)^T$ ，其中 $\mathbf{X} =$

$Z - \mathbb{E}Z$ (具体而言 $\mathbf{x}_i = \mathbf{z}_i - \boldsymbol{\mu}$, $\boldsymbol{\mu} = \frac{1}{n} \sum_{i=1}^n \mathbf{z}_i$)。

2. 计算 X 的协方差矩阵, 用 $\boldsymbol{\Sigma}_{p \times p}$ 表示

$$\text{Var} X = \text{Var}(Z - \mathbb{E}Z) = \text{Var} Z = \boldsymbol{\Sigma}$$

实际上 X 的协方差矩阵就是原始数据 Z 的协方差矩阵。

3. 计算协方差矩阵 $\boldsymbol{\Sigma}$ 的特征向量 $\{\boldsymbol{\xi}_j\}$ 和特征值 $\{\lambda_j\}$, $j = 1..p$ 。
4. 将特征值从小到大排序。
5. 保留前若干个特征值对应的特征向量, 假设保留的特征值为 $\{\lambda_j^*\}$, $j = 1..q$, 对应的特征向量构成的矩阵为 $\boldsymbol{\Xi}_{p \times q} = (\boldsymbol{\xi}_1^*, \boldsymbol{\xi}_2^*, \dots, \boldsymbol{\xi}_q^*)$
6. 将数据集 X 转换到上述 q 个特征向量构建的新的空间中, 得到新的数据集 $\mathbf{X}_{n \times q}^* =$

$$\mathbf{X}\boldsymbol{\Xi} = \begin{pmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \\ \dots \\ \mathbf{x}_i \\ \dots \\ \mathbf{x}_n \end{pmatrix} (\boldsymbol{\xi}_1^*, \boldsymbol{\xi}_2^*, \dots, \boldsymbol{\xi}_q^*)$$

3.2 主成分分析的数学原理

3.2.1 几个重要的定理

Theorem 3.2.1. $\boldsymbol{\Sigma}$ 为对称矩阵, 如下优化问题的解 \mathbf{u}^* 是 $\boldsymbol{\Sigma}$ 的最大特征值对应的特征向量。

$$\mathbf{u}^* = \arg \max_{\|\mathbf{u}\|=1} (\mathbf{u}^T \boldsymbol{\Sigma} \mathbf{u})$$

证明. 实际上约束条件 $\|\mathbf{u}\| = 1$ 等价于 $\mathbf{u}^T \mathbf{u} = 1$

利用拉格朗日乘子法, 得到

$$G(\mathbf{u}; \lambda) = \mathbf{u}^T \boldsymbol{\Sigma} \mathbf{u} + \lambda(\mathbf{u}^T \mathbf{u} - 1)$$

对 G 求 \mathbf{u} 的偏导得到

$$\nabla_{\mathbf{u}} G(\mathbf{u}; \lambda) = 2\boldsymbol{\Sigma} \mathbf{u} + 2\lambda \mathbf{u}$$

如果 \mathbf{u}^* 是优化问题的解, 那么 \mathbf{u}^* 满足

$$\begin{aligned}\nabla_{\mathbf{u}} G(\mathbf{u}; \lambda) \big|_{\mathbf{u}=\mathbf{u}^*} &= 0 \\ \Rightarrow \Sigma \mathbf{u}^* &= -\lambda \mathbf{u}^* \\ \Rightarrow \Sigma \mathbf{u}^* &= \lambda^* \mathbf{u}^* \quad (\text{令 } \lambda^* = -\lambda)\end{aligned}$$

所以 \mathbf{u}^* 是矩阵 Σ 的特征向量, 对应的特征值为 λ^* 。

当 $\mathbf{u} = \mathbf{u}^*$ 时, 目标函数

$$\mathbf{u}^{*T} \Sigma \mathbf{u}^* = \lambda^* \quad (3.1)$$

为使得公式 (3.1) 最大, 必须使得 λ^* 最大, 即 λ^* 等于矩阵 Σ 最大的特征值, 那么对应的特征向量便是真正的解 \mathbf{u}^* 。

□

3.2.2 最大方差投影

用 $\mathbf{u}_{p \times 1}$ 表示某投影方向上的单位向量, 那么 \mathbf{x}_i 在 \mathbf{u} 上的投影可以表示为

$$\langle \mathbf{x}_i, \mathbf{u} \rangle = \mathbf{x}_i^T \mathbf{u}$$

那么数据集 \mathbf{X} 在 \mathbf{u} 上的投影向量为 $\mathbf{Y} = \mathbf{X}\mathbf{u}$, 可知 \mathbf{Y} 的均值和方差为

$$\begin{aligned}\mathbb{E} \mathbf{Y} &= \mathbb{E} \mathbf{X} \mathbf{u} \\ \text{Var} \mathbf{Y} &= \text{Var} \mathbf{X} \mathbf{u} = \mathbf{u}^T (\text{Var} \mathbf{X}) \mathbf{u} = \mathbf{u}^T \Sigma \mathbf{u}\end{aligned}$$

主成分分析就是要到一个方向, 使得数据集 \mathbf{X} 在该方向上投影方差最大。如果用单位向量 \mathbf{u}_1 来表示这个方向, 那么 \mathbf{u}_1 是如下优化问题的解

$$\arg \max_{\|\mathbf{u}\|=1} \mathbf{u}^T \Sigma \mathbf{u}$$

根据定理 3.2.1, \mathbf{u}_1 就是 Σ 的最大特征值对应的特征向量, 也是第一个主成分的单位向量。

随后要求第二个主成分, 用单位向量 \mathbf{u}_2 表示这个方向。根据原理, 第二个主成分依然是要最大化投影的方差, 但是约束条件要多一个, 即 \mathbf{u}_2 与 \mathbf{u}_1 正交。所以 \mathbf{u}_2 是如下优化问题的解

$$\begin{aligned}\arg \max_{\|\mathbf{u}\|=1} \mathbf{u}^T \Sigma \mathbf{u} \\ s.t. \quad \mathbf{u}^T \mathbf{u}_1 = 0\end{aligned}$$

为求解上述优化问题，继续使用拉格朗日乘子法，得到

$$G(\mathbf{u}; \mathbf{u}_1, \lambda, \gamma) = \mathbf{u}^T \Sigma \mathbf{u} + (\mathbf{u}^T \mathbf{u} - 1) + \gamma \mathbf{u}^T \mathbf{u}_1$$

对 G 求 \mathbf{u} 的偏导得到，

$$\nabla_{\mathbf{u}} G(\mathbf{u}; \mathbf{u}_1, \lambda, \gamma) = 2\Sigma \mathbf{u} + 2\lambda \mathbf{u} + \gamma \mathbf{u}_1$$

如果 \mathbf{u}^* 是优化问题的解，那么 \mathbf{u}^* 满足

$$2\Sigma \mathbf{u}^* + 2\lambda \mathbf{u}^* + \gamma \mathbf{u}_1 = 0 \quad (3.2)$$

对公式 (3.2) 两边同乘以 \mathbf{u}_1^T ，得到

$$\begin{aligned} 2\Sigma \mathbf{u}^* \mathbf{u}_1^T + 2\lambda \mathbf{u}^* \mathbf{u}_1^T + \gamma \mathbf{u}_1 \mathbf{u}_1^T &= 0 \\ \Rightarrow \gamma \mathbf{u}_1 \mathbf{u}_1^T &= 0 \quad (\text{因为 } \mathbf{u}_1, \mathbf{u}^* \text{ 正交}) \\ \Rightarrow \gamma &= 0 \quad (\text{因为 } \mathbf{u}_1 \mathbf{u}_1^T = 1) \end{aligned}$$

于是公式 (3.2) 等于

$$\begin{aligned} \Sigma \mathbf{u}^* + \lambda \mathbf{u}^* &= 0 \\ \Rightarrow \Sigma \mathbf{u}^* &= -\lambda \mathbf{u}^* \\ \Rightarrow \Sigma \mathbf{u}^* &= \lambda^* \mathbf{u}^* \quad (\text{令 } \lambda^* = -\lambda) \end{aligned} \quad (3.3)$$

\mathbf{u}^* 也是矩阵 Σ 的特征值，与定理 3.2.1 的证明类似，优化问题的目标函数等于 λ^* ，为了使目标函数最大，要使 λ^* 尽量大，而 λ^* 最大可取所有特征值中第二大的，对应的特征向量就是优化问题的解，即**第二主成分**的方向向量。

后面的主成分算法同理类推。

Chapter 4

附录：数学基本方法

4.1 梯度

本节内容参考了Xu (2016)。

4.1.1 梯度与方向导数

函数在某点的

- **导数**表示函数曲线上的切线斜率，也表示函数在该点的变化率。
- **偏导数**是函数关于其某一个变量的导数，物理含义是函数沿着坐标轴正方向上的变化率。
- **方向导数**是函数在某点沿某个指定方向上的变化率。
- **梯度**是函数在该点沿所有方向变化率最大的那个方向，是一个向量。

4.1.2 梯度下降

设函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 的某空间领域内 $U \subset \mathbb{R}^2$ 有定义， l 为从点 P_0 出发的射线， $P(x, y)$ 为 l 上且在 U 内的任一点，令

$$x - x_0 = \Delta x = t \cos \alpha$$

$$y - y_0 = \Delta y = t \sin \alpha$$

以 $t = \sqrt{(\Delta x)^2 + (\Delta y)^2}$ 表示 P 与 P_0 之间的距离，若极限

$$\lim_{t \rightarrow 0^+} \frac{u(P) - u(P_0)}{t} = \lim_{t \rightarrow 0^+} \frac{u(x_0 + t \cos \alpha, y_0 + t \sin \alpha) - u(P_0)}{t}$$

存在，则称此极限为函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 沿着方向 l 的**方向导数**，记做 $\frac{\partial u}{\partial l} \Big|_{P_0}$ 。

Lemma 4.1.1. 假设函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 可微，则 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 沿着方向 l 的方向导数都存在，且

$$\frac{\partial u}{\partial l} \Big|_{P_0} = u'_x(P_0) \cos \alpha + u'_y(P_0) \sin \alpha \quad (4.1)$$

假设函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 存在一阶偏导数，则定义

$$\nabla u \Big|_{P_0} = (u'_x(P_0), u'_y(P_0))$$

为函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 的**梯度**。

Theorem 4.1.1. 函数 $u = u(x, y)$ 在点 $P_0(x_0, y_0)$ 处的方向导数在其梯度方向上达到最大值，此最大值为梯度的模。

证明. 根据方向导数的定义

$$\begin{aligned} \frac{\partial u}{\partial l} \Big|_{P_0} &= u'_x(P_0) \cos \alpha + u'_y(P_0) \sin \alpha \\ &= (u'_x(P_0), u'_y(P_0)) \cdot (\cos \alpha, \sin \alpha) \\ &= \nabla u \Big|_{P_0} \cdot l \\ &= |\nabla u \Big|_{P_0}| |l| \cos \theta \\ &= |\nabla u \Big|_{P_0}| \cos \theta \end{aligned}$$

其中 θ 为梯度向量 $\nabla u \Big|_{P_0}$ 与方向向量 l 的夹角。根据公式(公式 (4.2))可知，当夹角 $\cos \theta = 1$ ，即 $\theta = 0$ 时，方向导数 $\frac{\partial u}{\partial l} \Big|_{P_0}$ 取得最大值，此最大值为 $|\nabla u \Big|_{P_0}|$ 。□

Chapter 5

附录：概率论中的重要结论

5.1 Hoeffding不等式

本节内容参考了Rigollet (2015)。

Lemma 5.1.1 (Hoeffding 引理). 如果随机变量 $Z \in [a, b]$ a.s., 并且 $\mathbb{E}Z = 0$, 那么对于 $\forall s \in \mathbb{R}$, 都有

$$\mathbb{E}e^{sZ} \leq e^{\frac{s^2(b-a)^2}{8}} \quad (5.1)$$

证明. 令 $\psi(s) = \log \mathbb{E}e^{sZ}$, 由于 $Z \in [a, b]$ a.s., 对于给定的 s , e^{sZ} 是有界函数。

根据勒贝格控制收敛定理的结论, 可知 e^{sZ} 的积分和求导符号可互换, 那么得到

$$\begin{aligned} \psi'(s) &= \frac{\mathbb{E}Z e^{sZ}}{\mathbb{E}e^{sZ}} \\ \psi''(s) &= \frac{\mathbb{E}Z^2 e^{sZ} \mathbb{E}e^{sZ} - (\mathbb{E}Z e^{sZ})^2}{(\mathbb{E}e^{sZ})^2} = \mathbb{E}Z^2 \left(\frac{e^{sZ}}{\mathbb{E}e^{sZ}} \right) - \left(\mathbb{E}Z \frac{e^{sZ}}{\mathbb{E}e^{sZ}} \right)^2 \end{aligned}$$

因为 $\int \frac{e^{sZ}}{\mathbb{E}e^{sZ}} d\mathbb{P} = 1$, 可定义Radon-Nikodym导数

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \frac{e^{sZ}}{\mathbb{E}e^{sZ}} \quad (5.2)$$

由此引入一个新的概率测度 \mathbb{Q} 。 $\psi''(s)$ 可以看做 Z 在概率测度 \mathbb{Q} 下的方差

$$\begin{aligned}
 \psi''(s) &= \mathbb{E}^{\mathbb{Q}} Z^2 - (\mathbb{E}^{\mathbb{Q}} Z)^2 \\
 &= \text{Var}(Z) \\
 &= \text{Var}\left(Z - \frac{a+b}{2}\right) \quad (\text{随机变量加减常数不影响方差}) \\
 &\leq \mathbb{E}\left(Z - \frac{a+b}{2}\right)^2 \quad (\text{根据方差的定义}) \\
 &\leq \mathbb{E}\left(\frac{b-a}{2}\right)^2 \quad \left(\text{根据 } Z \in [a, b] \text{ 得到 } \left|Z - \frac{a+b}{2}\right| \leq \frac{b-a}{2}\right) \\
 &= \frac{(b-a)^2}{4}
 \end{aligned}$$

所以

$$\begin{aligned}
 \psi(s) &= \int_0^s \int_0^y \psi''(x) dx dy \leq \int_0^s \int_0^y \frac{(b-a)^2}{4} dx dy = \frac{s^2(b-a)}{8} \\
 \Rightarrow \log \mathbb{E} e^{sZ} &\leq \frac{s^2(b-a)}{8} \\
 \Rightarrow \mathbb{E} e^{sZ} &\leq e^{\frac{s^2(b-a)}{8}}
 \end{aligned}$$

□

Theorem 5.1.1 (Hoeffding定理). 假设 X_1, \dots, X_n 为 n 个独立的随机变量, 并且 $X_i \in [0, 1]$ a.s., 那么对于 $\forall s > 0$, 都有

$$\begin{aligned}
 P\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E} X_i) > t\right) &\leq e^{-2nt^2} \\
 P\left(\frac{1}{n} \sum_{i=1}^n (\mathbb{E} X_i - X_i) > t\right) &\leq e^{-2nt^2} \\
 P\left(\left|\frac{1}{n} \sum_{i=1}^n (\mathbb{E} X_i - X_i)\right| > t\right) &\leq 2e^{-2nt^2}
 \end{aligned}$$

Chapter 6

附录：信息熵

本章参考了(匿名, 2010)和(李梅, 2012)。

假设 X 是一个取有限值的离散随机变量(本文只考虑离散情况)，概率分布为 P 。

那么 $I(X = x_i) = -\log P(X = x_i)$ 称为事件 x_i 的**自信息量**，随机变量 X 的**熵**定义为 X 的自信息量的数学期望，即

$$H(X) = \mathbb{E}(I(X)) = - \sum_x P(x) \log P(x)$$

熵反映的是随机变量不确定程度的大小：熵的值越大，不确定程度越高。

6.1 相关概念

6.1.1 条件熵

条件熵是指在联合概率空间上熵的条件自信息的数学期望。在已知 X 时， Y 的条件熵为

$$H(Y|X) = \mathbb{E}_{x,y} I(y_j|x_i) = - \sum_x \sum_y P(x, y) \log P(y|x) \quad (6.1)$$

Lemma 6.1.1. 与公式 (6.1)等价的定义为给定 X 条件下 Y 的条件分布概率的熵的数学期望

$$H(Y|X) = \mathbb{E}_x H(Y|X = x) = \sum_x P(x) H(Y|X = x)$$

证明.

$$\begin{aligned}
 H(Y|X) &= - \sum_x \sum_y P(x, y) \log P(y|x) \\
 &= - \sum_x \sum_y P(x) P(y|x) \log P(y|x) \\
 &= - \sum_x P(x) \sum_y P(y|x) \log P(y|x) \quad (P(x) \text{ 与 } y \text{ 无关}) \\
 &= \sum_x P(x) \left[- \sum_y P(y|x) \log P(y|x) \right] \\
 &= \sum_x P(x) H(Y|X = x)
 \end{aligned}$$

□

$H(Y|X)$ 的含义是已知在 X 发生的前提下, Y 发生新带来的熵。

6.1.2 相对熵

相对熵, 也称**KL散度**, 交叉熵等, 定义为两个概率分布之比的数学期望。

设 $Q(x), P(x)$ 是随机变量 X 中取值的两个概率分布, 则 P 对 Q 的相对熵是

$$D_{\text{KL}}(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} = \mathbb{E}_x \log \frac{P(x)}{Q(x)} \quad (6.2)$$

相对熵可以用来度量两个随机变量的“距离”。

Lemma 6.1.2. 相对熵恒大于等于零。

证明. 对于任意分布 P, Q , 根据公式 (6.2), 可知

$$\begin{aligned}
 D_{\text{KL}}(P\|Q) &= \sum_x P(x) \log \frac{P(x)}{Q(x)} \\
 &= - \sum_x P(x) \log \frac{Q(x)}{P(x)} \\
 &\geq - \log \left(\sum_x P(x) \frac{Q(x)}{P(x)} \right) \quad (\text{对 } -\log x \text{ 应用 Jensen 不等式}) \\
 &= - \log \sum_x Q(x) \\
 &= - \log 1 \\
 &= 0
 \end{aligned}$$

□

6.1.3 互信息

两个随机变量 X, Y 的**互信息**，定义为 X, Y 的联合分布和独立分布乘积的相对熵

$$I(X, Y) = D_{\text{KL}}(P(X, Y) \| P(X)P(Y)) \quad (6.3)$$

Lemma 6.1.3. 互信息与条件熵满足如下关系

$$H(X|Y) = H(X) - I(X, Y) \quad (6.4)$$

证明. 根据公式 (6.2) 以及互信息的定义可知

$$I(X, Y) = \sum_{x,y} P(x, y) \log \frac{P(x, y)}{P(x)P(y)}$$

那么

$$\begin{aligned} H(X) - I(X, Y) &= - \sum_x P(x) \log P(x) - \sum_{x,y} P(x, y) \log \frac{P(x, y)}{P(x)P(y)} \\ &= - \sum_x \left(\sum_y P(x, y) \right) \log P(x) - \sum_{x,y} P(x, y) \log \frac{P(x, y)}{P(x)P(y)} \\ &= - \sum_{x,y} P(x, y) \log P(x) - \sum_{x,y} P(x, y) \log \frac{P(x, y)}{P(x)P(y)} \\ &= - \sum_{x,y} P(x, y) \left(\log P(x) + \log \frac{P(x, y)}{P(x)P(y)} \right) \\ &= - \sum_{x,y} P(x, y) \log \frac{P(x, y)}{P(y)} \\ &= - \sum_{x,y} P(x, y) \log P(x | y) \\ &= H(X|Y) \quad (\text{根据公式 (6.1)}) \end{aligned}$$

□

6.2 熵的性质

X 的熵具有如下几个性质

- 非负性： $H(X) \geq 0$ 。¹
- 对称性：当随机变量的概率取值任意互换时，熵不变。

$$H(p_1, p_2 \dots p_n) = H(p_2, p_1 \dots p_n) = H(p_3, p_1 \dots p_n) = \dots$$

- 可加性：如果随机变量 X, Y 相互独立，则 $H(X, Y) = H(X) + H(Y)$ 。
- 极值性：对于任意概率分布 $P(X = x_i) = p_i$ 和 $P(Y = y_i) = q_i$ ， $i = 1 \dots n$ ，都有

$$H(X) = - \sum_{i=1}^n p_i \log p_i \leq - \sum_{i=1}^n p_i \log q_i \quad (6.5)$$

当 X 和 Y 的概率分布相同时，公式 (6.5) 取等号。

该性质表明，任意概率分布，它对其他概率分布的自信息取数学期望时，必大于它本身的熵。

- 凸性：对于任意概率分布 $P(X = x_i) = p_i$ 和 $P(Y = y_i) = q_i$ ， $i = 1 \dots n$ ，假设随机变量 Z 的分布为 $P(Z = z_i) = \gamma_i = \alpha p_i + (1 - \alpha) q_i$ ， $\alpha \in [0, 1]$ ，那么 Z 的熵满足

$$H(Z) \geq \alpha H(X) + (1 - \alpha) H(Y) \quad (6.6)$$

Theorem 6.2.1 (最大熵定理). 离散随机变量 X 的概率分布为 $P(X = x_i) = p_i$ ， $i = 1 \dots n$ ，那么

$$H(X) \leq \log n \quad (6.7)$$

当 $p_1 = p_2 = \dots = \frac{1}{n}$ 时，等号成立。

证明. 求熵的最大值等价于以下优化问题

$$\begin{aligned} \max \quad & H(x) = - \sum_{i=1}^n p_i \log p_i \\ \text{s.t.} \quad & \sum_{i=1}^n p_i = 1 \end{aligned}$$

利用拉格朗日乘子法构造函数

$$G(p, \lambda) = - \sum_{i=1}^n p_i \log p_i + \lambda \left(\sum_{i=1}^n p_i - 1 \right) \quad (6.8)$$

¹实际上这种非负性对于离散随机变量 X 成立，对连续随机变量 X 不一定成立。这是本文只考虑离散情况的原因。

公式 (6.8) 中分别对 p_i 和 λ 求导，令其为零，得到

$$\begin{aligned} \frac{\partial G(p, \lambda)}{\partial p_i} &= -\log p_i - 1 + \lambda = 0 \\ \sum_{i=1}^n p_i - 1 &= 0 \end{aligned} \tag{6.9}$$

由 $-\log p_i - 1 + \lambda = 0$ 可得到 $p_i = e^{\lambda-1}, i = 1, 2, \dots, n$, 由此可知 $p_1 = p_2 = \dots = \frac{1}{n}$

□

Lemma 6.2.1 (熵的强可加性). 当随机变量 X, Y 相关的情况下，联合熵满足强可加性，即

$$\begin{aligned} H(X, Y) &= H(Y) + H(X|Y) \\ H(X, Y) &= H(X) + H(Y|X) \end{aligned} \tag{6.10}$$

证明.

$$\begin{aligned} H(Y) + H(X|Y) &= - \sum_y P(y) \log P(y) - \sum_x \sum_y P(x, y) \log P(x|y) \\ &= - \sum_x \sum_y P(x, y) \log P(y) - \sum_x \sum_y P(x, y) \log P(x|y) \\ &= - \sum_x \sum_y P(x, y) \log P(x, y) \\ &= H(X, Y) \end{aligned}$$

同理可证

$$H(X, Y) = H(X) + H(Y|X)$$

□

Lemma 6.2.2 (熵的凸性). 证明公式 (6.6)

证明.

$$\begin{aligned}
 H(Z) &= - \sum_{i=1}^n \gamma_i \log \gamma_i \\
 &= - \sum_{i=1}^n \alpha p_i \log \gamma_i - \sum_{i=1}^n (1 - \alpha) q_i \log \gamma_i \\
 &= - \sum_{i=1}^n \alpha p_i \log \left(\gamma_i \frac{p_i}{p_i} \right) - \sum_{i=1}^n (1 - \alpha) q_i \log \left(\gamma_i \frac{q_i}{q_i} \right) \\
 &= - \alpha \sum_{i=1}^n p_i \log p_i - (1 - \alpha) \sum_{i=1}^n q_i \log q_i - \alpha \sum_{i=1}^n p_i \log \frac{\gamma_i}{p_i} - (1 - \alpha) \sum_{i=1}^n q_i \log \frac{\gamma_i}{q_i} \\
 &= \alpha H(X) + (1 - \alpha) H(Y) - \alpha \sum_{i=1}^n p_i \log \frac{\gamma_i}{p_i} - (1 - \alpha) \sum_{i=1}^n q_i \log \frac{\gamma_i}{q_i}
 \end{aligned} \tag{6.11}$$

其中公式 (6.11) 的倒数第二项

$$\begin{aligned}
 -\alpha \sum_{i=1}^n p_i \log \frac{\gamma_i}{p_i} &= \alpha \left(- \sum_{i=1}^n p_i \log \gamma_i + \sum_{i=1}^n p_i \log p_i \right) \\
 &\geq 0 \quad (\text{根据公式 (6.5)})
 \end{aligned}$$

同理可知公式 (6.11) 的倒数第一项

$$-(1 - \alpha) \sum_{i=1}^n q_i \log \frac{\gamma_i}{q_i} \geq 0$$

所以得到

$$H(Z) \geq \alpha H(X) + (1 - \alpha) H(Y)$$

□

Theorem 6.2.2. 条件熵小于无条件熵，即 $H(X|Y) \leq H(X)$

证明.

$$\begin{aligned}
 H(X|Y) - H(X) &= - \sum_{x,y} P(x,y) \log P(x|y) + \sum_x P(x) \log P(x) \\
 &= - \sum_{x,y} P(x,y) \log P(x|y) + \sum_x \left(\sum_y P(x,y) \right) \log P(x) \\
 &= - \sum_x \sum_y P(y) P(x|y) \log P(x|y) + \sum_x \sum_y P(y) P(x|y) \log P(x) \\
 &= - \sum_y P(y) \left(\sum_x P(x|y) \log P(x|y) - \sum_x P(x|y) \log P(x) \right)
 \end{aligned}$$

根据熵的极值性, 可知

$$\begin{aligned}
 - \sum_x P(x|y) \log P(x|y) &\leq - \sum_x P(x|y) \log P(x) \\
 \Rightarrow \sum_x P(x|y) \log P(x|y) - \sum_x P(x|y) \log P(x) &\geq 0 \\
 \Rightarrow H(X|Y) - H(X) &\leq 0
 \end{aligned}$$

所以

□

6.2.1 整理得到的公式

根据本节内容整理得到的重要公式

- 根据条件熵定义可得

$$H(X|Y) = H(X, Y) - H(Y) \quad (6.12)$$

- 根据互信息定义展开可得

$$H(X|Y) = H(X) - I(X, Y) \quad (6.13)$$

- 根据公式 (6.12) 和公式 (6.13) 得到的对偶形式

$$\begin{aligned}
 H(Y|X) &= H(X, Y) - H(X) \\
 H(Y|X) &= H(Y) - I(X, Y)
 \end{aligned}$$

- 多数文献将下式作为互信息的定义公式

$$I(X, Y) = H(X) + H(Y) - H(X, Y)$$

- $H(X|Y) \leq H(X)$

Chapter 7

附录：贝叶斯决策论

7.1 先验概率与后验概率

此部分参考了夏飞 (2017)。

7.1.1 概念

$$P(\theta|X) = \frac{P(X|\theta)P(\theta)}{P(X)} \quad (7.1)$$

公式 (7.1) 中 $P(\theta|X)$ 称为**后验概率**， $P(X|\theta)$ 称为**条件概率** (也是似然估计中的**似然函数**)， $P(\theta)$ 称为**先验概率**， $P(X)$ 是随机变量 X 自身的概率， $P(X)$ 也被称为“证据” (evidence)。

7.1.2 频率学派与贝叶斯学派

对于概率的认知有频率学派和贝叶斯学派两种。

- 频率学派：模型参数是未知的定值，观测是随机变量。估计的方法是**极大似然估计** (Maximum Likelihood)，不依赖于先验概率。
- 贝叶斯学派：模型参数是随机变量，观测是定值。估计的方法是**最大后验估计** (Maximum a posteriori)：根据已有的经验和知识推断一个先验概率，然后在新证据不断积累的情况下调整这个概率。

7.1.3 参数估计：极大似然与最大后验

极大似然估计(ML)与最大后验估计(MAP)的数学方法的区别如下。

- 极大似然估计(ML)把似然函数 $P(X|\theta)$ 取得最大值时的参数作为估计值。(对数)极大似然函数的估计参数可以写成

$$\hat{\theta}_{ML} = \arg \max_{\theta} P(X|\theta) = \arg \max_{\theta} \sum_{x \in X} \log P(x|\theta)$$

- 最大后验估计(MAP)与极大似然估计的区别在于加入了先验概率 $P(\theta)$,

$$\begin{aligned} \hat{\theta}_{MAP} &= \arg \max_{\theta} P(\theta|X) \\ &= \arg \max_{\theta} \frac{P(X|\theta)P(\theta)}{P(X)} \\ &= \arg \max_{\theta} P(X|\theta)P(\theta) \\ &= \arg \max_{\theta} \left(\sum_{x \in X} \log P(x|\theta) + \log P(\theta) \right) \end{aligned}$$

7.2 共轭分布

在贝叶斯理论中, 如果后验概率 $P(\theta|X)$ 和先验概率 $P(\theta)$ 满足同样的分布律, 那么先验概率分布和后验概率分布就叫做**共轭分布**, 同时先验分布叫做似然函数的**共轭先验分布**。

Theorem 7.2.1. 二项分布的共轭先验是Beta分布。

证明. 假设

- 先验分布为Beta分布, $\theta \sim \beta(\alpha, \beta)$, 那么 $P(\theta|\alpha, \beta) = \frac{1}{\beta(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$, 其中 $\beta(\alpha, \beta) = \int_0^1 \theta^{\alpha-1} (1-\theta)^{\beta-1} d\theta = \frac{G(\alpha)G(\beta)}{G(\alpha+\beta)}$
- 似然概率服从二项分布, $P(X = k|\theta) = C_n^k \theta^k (1-\theta)^{n-k}$

后验概率

$$\begin{aligned}
 P(\boldsymbol{\theta}|X = k) &= \frac{P(X = k|\boldsymbol{\theta})P(\boldsymbol{\theta})}{P(X = k)} \\
 &= \frac{P(X = k|\boldsymbol{\theta})P(\boldsymbol{\theta})}{\int_0^1 P(\boldsymbol{\theta}, X = k)d\boldsymbol{\theta}} \\
 &= \frac{P(X = k|\boldsymbol{\theta})P(\boldsymbol{\theta})}{\int_0^1 P(X = k|\boldsymbol{\theta})p(\boldsymbol{\theta})d\boldsymbol{\theta}} \\
 &= \frac{C_n^k \boldsymbol{\theta}^k (1 - \boldsymbol{\theta})^{n-k} \frac{1}{\beta(\alpha, \beta)} \boldsymbol{\theta}^{\alpha-1} (1 - \boldsymbol{\theta})^{\beta-1}}{\int_0^1 C_n^k \boldsymbol{\theta}^k (1 - \boldsymbol{\theta})^{n-k} \frac{1}{\beta(\alpha, \beta)} \boldsymbol{\theta}^{\alpha-1} (1 - \boldsymbol{\theta})^{\beta-1} d\boldsymbol{\theta}} \\
 &= \frac{\boldsymbol{\theta}^{\alpha+k-1} (1 - \boldsymbol{\theta})^{\beta+n-k-1}}{\int_0^1 \boldsymbol{\theta}^{\alpha+k-1} (1 - \boldsymbol{\theta})^{\beta+n-k-1} d\boldsymbol{\theta}} \\
 &= \frac{\boldsymbol{\theta}^{\alpha+k-1} (1 - \boldsymbol{\theta})^{\beta+n-k-1}}{B(\alpha + k, \beta + n - k)} \quad \left(\text{根据定义 } B(\alpha, \beta) = \int_0^1 \boldsymbol{\theta}^{\alpha-1} (1 - \boldsymbol{\theta})^{\beta-1} d\boldsymbol{\theta} \right)
 \end{aligned}$$

后验概率也服从Beta分布 $\boldsymbol{\theta}|X = k \sim \beta(\alpha + k, \beta + n - k)$ ，故二项分布的共轭先验是Beta分布。

□

参考文献

- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press. iii
- Rigollet, P. (2015). Lecture note, mathematics of machine learning, mit open course. 1, 14
- Xu, L.-C. (2016). 理解梯度下降. 12
- 匿名 (2010). 信息论与编码. 16
- 夏飞 (2017). 聊一聊机器学习的mle和map. 24
- 李梅 (2012). 信息论基础. 16
- 李航 (2012). 统计学习方法. 清华大学出版社. 1

索引

Conditional independence, v

Covariance, v

Derivative, v

Determinant, iv

Element-wise product, *see* Hadamard product

Graph, iv

Hadamard product, iv

Hessian matrix, v

Independence, v

Integral, v

Jacobian matrix, v

Kullback-Leibler divergence, v

Matrix, iii, iv

Norm, vi

Scalar, iii, iv

Set, iv

Shannon entropy, v

Sigmoid, vi

Softplus, vi

Tensor, iii, iv

Transpose, iv

Variance, v

Vector, iii, iv